CiteMind 项目说明与使用手册

证据 AI 知识库

版本 v1.1 更新于 2026年10月18日

1 项目概览

CiteMind 是面向个人资料的浏览器端知识检索应用。导入笔记、项目文档或带文字层的 PDF 后，用户可以围绕资料提问，阅读相关原句，并通过引用核对来源。本手册说明本地启动、实际功能、数据保存、实现方式和简历展示方法。

当前版本能做什么

功能	使用结果
资料导入	支持 PDF、TXT、Markdown、粘贴文字，内置 5 篇中文示例资料。
两种检索	快速模式按词语相关度检索；本地 AI 模式使用中文句向量，支持语义相近的表达。
引用核对	返回原文摘录与编号引用；PDF 来源保留物理页码，可切换文字页并核对高亮。
保存与迁移	可选保存在当前浏览器，支持 JSON 知识库备份、合并或替换恢复。
问答导出	将当前问答、模式、检索耗时和来源导出为 Markdown。

准确理解 AI 的作用

AI 部分把问题和资料转换为向量，用于寻找意思相近的内容。回答直接摘录检索到的原文；当前没有接入生成式大语言模型，不提供跨资料的生成式总结或自由对话。可以将本项目定位为生成式 RAG 可使用的检索与证据层。

资料相关性不足时，应用提示资料不足。排序分数只表示检索相关度，不能解释成事实正确概率。原文自身可能有错误，最终判断仍需核对来源。示例知识库是虚构产品资料，用于展示功能。

当前交付与访问状态

完整源码包可通过 Windows 启动入口在本机运行；静态部署包用于更换托管平台。原 chatgpt.site 地址已被用户浏览器和此前检查确认遭到 Cloudflare 拦截，暂不能用作有效的简历演示链接。新的公开入口应完成真实访问验证后再填写。

项目不要求 API Key。首次使用 PDF 或本地 AI 仍需下载公共组件和模型；当前不承诺首次离线可用。

2 启动应用与首次体验

建议先在本地完成一次完整演示，再部署公开入口。快速检索无需下载模型，适合先确认导入、提问和引用功能。

Windows 启动步骤

1. 安装 Python 3，并完整解压 CiteMind v1.1 源码包。不要直接在压缩包内运行。

2. 双击“启动应用.cmd”。脚本启动本机静态服务，并在浏览器打开应用。

3. 默认地址为 http://127.0.0.1:4173。端口被占用时依次尝试 4174 至 4182；以服务窗口显示的地址为准。

4. 体验过程中保持服务窗口打开。关闭该窗口即可停止本机服务。

若自动打开浏览器失败，可手动打开服务窗口显示的地址。页面使用 ES Modules 和独立 Worker，需要通过 HTTP 或 HTTPS 访问，直接双击 index.html 打开的 file 地址不适用。

备用启动方式

在源码项目目录打开终端，运行下面的命令；无需安装前端构建工具。Python 只提供静态文件，不承担资料解析或模型推理。

```
python tools/serve.py --no-browser
```

也可使用 Python 标准库，明确指定 dist 为站点目录：

```
python -m http.server --bind 127.0.0.1 4173 --directory dist
```

五分钟演示顺序

时间	操作与展示重点
第 1 分钟	使用示例资料提问“这个知识库如何避免 AI 编造答案？”，打开一条引用。
第 2 分钟	导入自己的 TXT 或带文字层的 PDF，针对其中一个事实提问。
第 3 分钟	点击 PDF 来源，核对物理页码、提取文字及命中原句。
第 4 分钟	在“保存与备份”开启本机保存，导出 JSON，再刷新核对资料恢复。
第 5 分钟	导出问答记录；模型已就绪时展示语义改写问题，并测试一个无关问题。

首次模型下载可能超过演示时间。面试前先完成一次下载和预演，同时保留快速检索流程；不要把已缓存加载时间描述为首次访问速度。

3 资料导入提问与引用核对

左侧“选择文件”支持多文件选择和拖放；“或直接粘贴文本”可添加有标题的纯文本资料。资料加入后，输入问题并按 Enter 发送，Shift + Enter 换行。

输入项目	当前限制
PDF	单份不超过 10 MB、80 页，提取文字不超过 100,000 字符。
PDF 类型	需要可提取的文字层。不支持扫描件 OCR、加密或受权限保护的 PDF。
TXT 和 Markdown	使用 UTF-8 编码；单文件不超过 1 MB，单篇不超过 100,000 字符。
知识库总量	最多 20 篇资料，原文合计不超过 250,000 字符。
输入问题	单次最多 1,000 字符；当前对话最多 20 轮，达到后先导出记录，再新建对话。
JSON 备份	单份不超过 6 MB，恢复时再次校验文档和 PDF 页码信息。

如何提问更容易核对

围绕资料中可验证的事实提问，例如“单份 PDF 支持多少页”“开启保存后资料在哪里”“项目如何处理没有证据的问题”。本地 AI 模式可尝试改写为“我的资料会不会被传走”，观察是否返回对应隐私原句。结果以实际资料为准。

右上角“快速检索”可切换到“本地 AI 语义检索”。首次启用显示下载进度，可取消、重试。加载失败时，快速检索仍可使用；本地 AI 不会自动变成远程模型调用。

如何阅读引用

回答的编号对应来源卡片。点击来源后，核对资料标题与高亮原句。PDF 显示提取文字和物理页码，不展示原 PDF 页面图像。物理第 3 页可能与文档印刷页码不同，应以原文件的页面顺序核对。

PDF 保留空白页信息，分块不跨页。可以切换指定页或查看全部提取文字。复杂表格、多栏排版和公式可能出现阅读顺序或提取偏差，重要内容应回到原 PDF 确认。没有文字层的扫描件需先用其他工具做 OCR。

问答记录与无关问题

每次检索显示本次实际耗时。回答下方可复制带来源的内容或“导出记录”，保存为 Markdown。对资料外的问题，例如“明天杭州会下雨吗”，应看到资料不足提示；这不等于应用具备实时天气查询能力。

4 本机保存备份与隐私

“保存与备份”用于管理知识库文字。“导出记录”用于保存问答。两类导出包含的内容不同，迁移设备前应分别检查。

方式	包含的内容	不包含的内容
当前页面内存	文档、检索索引及当前问答；只在本次页面会话使用。	刷新后的持续保存或跨设备同步。
浏览器本机保存	当前知识库文字、文档信息与 PDF 分页元数据。	原始 PDF、聊天记录、模型向量。
JSON 知识库备份	文档标识、标题、原文、PDF 页码与位置。	原始 PDF、聊天记录、模型向量。
Markdown 问答导出	当前问答、检索模式、耗时、来源与原文摘录。	可直接恢复的完整知识库。

开启和关闭本机保存

本机保存默认关闭，此时刷新会恢复示例资料。打开“保存与备份”，开启“保存在此浏览器”，等待状态显示保存完成后再刷新。开启后，资料写入 IndexedDB；同一浏览器访问同一站点地址时可恢复。

关闭本机保存会移除浏览器中的资料副本，当前页面仍可继续使用资料。清除站点数据、使用无痕窗口、更换浏览器、端口、域名或设备，都可能无法读取原有资料。更换部署地址之前应先导出 JSON。

导出和恢复知识库

1. 点击“导出知识库”，保留下载的 JSON；文件含资料原文，应与原始文件一起妥善保存。
2. 恢复时先选择导入方式，再点击“导入备份”。“合并到当前资料”保留现有内容，按标题、原文和类型去重；冲突的文档标识会重建。
3. “替换当前资料”使用备份覆盖当前知识库，并清空旧对话。合并新增资料也会重建索引并清空当前对话，操作前可先导出问答。
4. 备份格式、范围或分页信息无效时应拒绝恢复；不要把失败提示理解为已经覆盖成功。

哪些数据会发生网络请求

文档解析、检索和向量计算在浏览器中完成，应用不把资料或问题发送到应用服务器或远程推理接口。首次 PDF 导入与本地 AI 启用会访问公共 CDN、Hugging Face 下载组件或模型，这些服务可能收到常规网络请求。托管服务也可能记录普通访问日志。

模型文件可能被浏览器缓存，资料向量仅保留在页面内存。模型缓存、JSON 备份和本机知识库是不同的数据；缓存被清理后可能需要重新下载模型。

5 技术结构与检索过程

应用由静态页面和浏览器内计算组成。公开部署不需要业务后端数据库，Python 只用于本机提供静态文件。

模块	职责
app.js	导入、提问、引用面板、模型状态、本机保存与导出交互。
engine.js	资料分块、词语检索、语义召回、句级重排与原文位置。
model.js	独立 Worker 中加载模型、批量推理、排队、取消与超时重试。
pdf.js	加载 PDF.js，提取文字并保留连续物理页码与位置。
storage.js	IndexedDB 读写、备份序列化、输入校验及恢复。

从资料到证据

1. 分块：按句段边界切为最多 420 字符的块，相邻块保留 64 字符重叠；PDF 页边界优先，不跨页切块。
2. 快速检索：结合中文分词、汉字片段与英文技术词，参考 BM25 的词频、稀有度、块长度和标题匹配排序，再选择相关原句。
3. 语义召回：将问题和资料块转换为向量，按余弦相似度召回候选块，并复用内存中的向量。
4. 句级重排：继续嵌入候选原句，按与问题的语义接近程度重新排序，词语匹配只作补充。
5. 返回引用：输出原句、文档标识、分块标识、原文位置和可选 PDF 页码；界面按文本展示内容并高亮出处。

本地 AI 的实际配置

使用 Transformers.js 3.8.1 和 ONNX Runtime / WASM，模型为 Xenova/bge-small-zh-v1.5。q8 权重约 24 MB，另需分词器和 WASM 组件；使用 CLS 池化，得到 512 维归一化向量。首次下载体积和初始化开销不等于单次检索耗时。

模型加载和推理放入 Web Worker，减少计算对页面输入及滚动的影响。小批量排队、缓存、加载进度、取消和超时重试用于管理等待与错误。当前采用内存检索，资料规模超过现有上限时需要重新评估索引方案。

引用为什么能对应原文

PDF 分页元数据保存 pageNumber、text、start、end，页码从 1 连续递增并保留空白页。引用使用 JavaScript UTF-16 索引指向原文，避免清理或裁剪文字导致位置错位。用户内容通过文本节点显示，不作为 HTML 执行。

6 验证范围与简历使用

目前的验证证明特定功能和交互能够工作，尚未形成大规模检索质量评估。简历可以描述实现内容和已完成检查，效果数据应来自后续实际测量。

验证项	已保留的检查记录
自动功能检查	引擎 16 项、存储 8 项，共 24 项；覆盖引用位置、PDF 页码、无关资料、句级重排、缓存、错误嵌入和备份校验。
浏览器存储	9 个流程，含默认不保存、显式开启、刷新恢复、合并去重、替换恢复、异常备份及关闭删除。
PDF 界面	7 个流程，含真实上传、三页元数据、物理第 3 页引用、高亮、空白页与全部文字。
真实模型	Chrome 中使用真实 BGE 和 ONNX 推理，验证语义改写、无关问题与可追溯引用。该轮用校验过的官方资源字节作为测试缓存。
保存顺序	连续编辑时，最新资料真正提交后才显示保存完成；刷新恢复最新状态。

注入向量的算法检查与真实模型推理验证承担不同目的。上述记录不能证明生产网络首次下载稳定，也不能推导准确率、Recall@K、MRR、用户量或业务收益。当前没有这些指标的实测结论。

可用于简历的项目表述

CiteMind 证据知识库 浏览器端 AI 语义检索应用

技术栈：JavaScript ES Modules、Transformers.js、ONNX Runtime / WASM、Web Worker、PDF.js、IndexedDB。在线演示地址在实际可访问后填写。

1. 实现 PDF、TXT、Markdown 导入与重叠分块，保留 PDF 页码和原文位置，支持来源高亮核对及带引用的 Markdown 问答导出。
2. 在独立 Worker 运行中文 BGE 嵌入模型，实现相关块召回与句级语义重排，并处理批量排队、向量缓存、加载取消、超时与重试。
3. 实现默认关闭的 IndexedDB 本机保存及 JSON 备份恢复，校验原文与分页元数据；编写 24 项引擎和存储功能检查。

面试时如何介绍

我实现了一个在浏览器中处理个人资料的知识检索应用。用户导入文本或带文字层的 PDF 后，可以提问并按引用核对原句和 PDF 页码。AI 部分在本地运行中文嵌入模型，先召回资料块，再对候选句做语义重排。知识库可选保存在浏览器，也能用 JSON 迁移。当前回答来自资料摘录，没有接入生成式大语言模型。

请根据自己实际理解和参与情况调整主语，只保留能独立解释的内容。后续可建立人工标注问题集，对比快速检索和语义检索，并分别记录首次下载、首次向量化及已缓存检索耗时。

7 部署要求与常见问题

可将 dist 目录中的文件部署到支持 HTTPS 的静态托管服务。入口文件应在站点根目录，ES Modules 和 Worker 应以正确类型加载。应用可加载与本地 AI 资源能下载，需要分别验证。

网络依赖和迁移检查

PDF.js 使用固定版本 6.4.299，运行组件和 AI 依赖也使用固定版本或模型修订。浏览器需访问公共 CDN 与 Hugging Face。当前部署包没有把全部模型和运行组件随站点打包，首次下载受用户网络影响；缓存存在也不等于完整离线支持。

迁移时保持文件相对路径，发布完整 dist 内容。更换域名或端口前先导出知识库与问答；新地址与旧地址的浏览器存储互不共享。验证页面、脚本、PDF、AI 模型及保存恢复后，再把公开入口加入简历。

当前公开入口状态

原地址 https://citemind-ai-xxf.eagerrose256.chatgpt.site 有发布记录，但用户截图和此前访问检查均出现 Cloudflare 拦截，不能当作已验证可用入口。继续尝试的托管结果应以本次交付消息和访问验证记录为准；临时测试地址不代表长期稳定托管。

遇到问题时按现象检查

现象	处理方式
启动窗口一闪而过	确认 Python 3 可运行、源码已完整解压，再在项目目录执行备用启动命令查看提示。
页面空白或模块报错	使用本机服务给出的 HTTP 地址；确认静态托管的 JS 文件路径和类型正确。
模型一直加载或失败	检查公共资源网络访问，取消后重试；可继续使用快速检索。不要把本地资料上传当作解决办法。
PDF 组件加载失败	首次使用需要公共 CDN；检查网络后重试。文本导入与快速检索可先使用。
PDF 提取为空或顺序异常	检查是否为扫描件或复杂分栏；先做 OCR 或转为 UTF-8 文本，并回原 PDF 核对。
刷新后资料或对话消失	资料需显式开启本机保存并等待完成。聊天记录不持久化，应另外导出 Markdown。
备份导入失败	检查 JSON 是否为本应用备份、大小不超 6 MB、总量未超限；保留原文件，不手工删改分页字段。
打开链接显示被拦截	记录错误页面、时间及 Ray ID，核对托管访问设置或更换合法托管入口；应用界面改动不能消除平台拦截。

进一步开发可从扫描件 OCR、增量索引和人工标注评估集开始。加入生成式回答时，还需单独实现资料远程发送告知、服务端密钥保护和引用校验。